Qwen

Da Orquestração Central à Colaboração de Microserviços: Um Fluxo Integrado dos Planos de Controle e Usuário no 5G NSA e SA

Este relatório apresenta uma análise aprofundada e comparativa das arquiteturas de rede móvel 5G Não Autônoma (NSA) e 5G Autônomo (SA). O objetivo central é fornecer uma compreensão conceitual integrada dos seus componentes e fluxos de funcionamento, abrangendo simultaneamente o plano de controle, responsável pela sinalização e gerenciamento, e o plano de usuário, que trata do encaminhamento do tráfego de dados. A análise se distingue por não se limitar a descrições procedimentais, mas sim por construir uma narrativa lógica sobre como os elementos de hardware e software colaboram para criar um serviço de rede coeso. A estrutura do relatório percorre a trajetória evolutiva da tecnologia, começando com a solução pragmática e transitória do NSA, que reutiliza a infraestrutura 4G, e avança para a plataforma de computação nativa da nuvem do SA, projetada desde o início para ser flexível, programável e escalável. Cada seção destina-se a desvendar a lógica subjacente que governa cada arquitetura, destacando suas dependências fundamentais, seus pontos de otimização e as implicações estratégicas de sua filosofia de design.

Fundamentos da Transição: A Arquitetura Híbrida e Dependente do 5G Não Autónomo

O 5G Não Autônomo (NSA) representa a primeira fase de implantação da tecnologia 5G em escala global, concebida como uma solução de transição pragmática [6]. Sua principal característica definidora é a natureza híbrida e dependente da sua arquitetura; ela não é um sistema completo, mas sim uma camada de rádio superior superposta a uma infraestrutura de núcleo de rede existente e madura [1] [2]. Esta dependência fundamental explica tanto as vantagens competitivas iniciais que impulsionaram sua adoção, como as limitações intrínsecas que a relegam a um papel de ponte tecnológica. A

palavra-chave que resume o NSA é "híbrido": a rede combina duas tecnologias de acesso a rádio distintas — a 4G LTE e a nova 5G New Radio (NR) — sob uma única abertura de conexão do dispositivo do usuário [3] [5]. No entanto, esta dualidade de rádio contrasta fortemente com a monoliticidade do seu núcleo de rede, que continua sendo o Evolved Packet Core (EPC) desenvolvido para a era 4G [1] [17].

A arquitetura mais comum e recomendada para o NSA é definida pelo padrão 3GPP como a Opção 3x, que utiliza a tecnologia de conectividade dupla E-UTRA-NR (EN-DC) [1] [3]. Esta configuração permite que o dispositivo do usuário (UE, ou User Equipment) mantenha uma conexão simultânea e ativa tanto com uma estação base 4G (eNB) quanto com uma estação base 5G (gNB) [1] [6]. Em termos conceituais, esta relação é hierárquica. A rede 4G LTE atua como o "ancoradouro" ou o cérebro da operação, enquanto a rede 5G NR funciona como um braço adicional, projetado para aumentar drasticamente a capacidade de transmissão de dados do usuário [1] [2]. Essa abordagem permitiu às operadoras de telecomunicações acelerar significativamente o lançamento comercial da tecnologia 5G, aproveitando bilhões de dólares em investimentos já feitos na rede de núcleo 4G e nos mastros de antenas 4G espalhados por vastas áreas geográficas [4] [6]. A estratégia foi clara: oferecer aos consumidores a promessa de velocidades 5G imediatamente, mesmo que o coração da rede permanecesse tecnologicamente anacrónico. Os principais componentes desta arquitetura híbrida são o núcleo 4G (EPC), a estação base mestra 4G (eNB) e a estação base secundária 5G (gNB).

Componente	Tecnologia	Função Principal na Arquitetura NSA
Núcleo de Rede	4G Evolved Packet Core (EPC)	Gerencia toda a sinalização de controle, autenticação, cobrança e roteamento básico de pacotes [1] [2] [17].
Estação Base Mestra	4G eNB (Evolved NodeB)	Atua como o ponto de ancoragem para todo o plano de controle. É responsável pela comunicação com o EPC, gestão de mobilidade e estabelecimento da conexão inicial [1] [7] [17].
Estação Base Secundária	5G gNB (5G NodeB)	Fornece capacidade de rádio extra para o plano de usuário. Aumenta a largura de banda total através da agregação de dados, mas não tem autonomia para sinalização de controle independente [1] [4] [17].

A tecnologia que torna essa arquitetura possível é a conectividade dupla (EN-DC), que define como o UE pode ser servido simultaneamente por uma célula primária (na rede LTE) e uma célula secundária (na rede NR) [6] [7]. O eNB, como nó mestre, detém a conexão de rádio cósmico (RRC) com o UE e a controla, enquanto a gNB, como nó secundário, é adicionada dinamicamente para fornecer recursos de rádio extras [4] [7]. A interação entre esses componentes é coordenada através de interfaces específicas. O eNB mantém as interfaces S1-MME (para sinalização de controle) e S1-U (para dados) com o EPC, bem como interfaces X2-C (controle) e X2-U (usuário) com a gNB [7] [18].

Crucialmente, na maioria das implementações NSA, a gNB não possui uma interface direta com o EPC; ela depende exclusivamente do eNB para se comunicar com o núcleo de rede [7]. Isso solidifica a posição subordinada da conectividade 5G no modelo NSA, onde ela serve como um mero acelerador de dados, orquestrado por uma entidade de controle 4G. A eficiência e o desempenho real da rede NSA, portanto, não dependem apenas da capacidade bruta do rádio 5G, mas sim da inteligência e da capacidade de processamento do eNB e do EPC para gerenciar a complexidade dessa operação dual. A decisão de dividir o tráfego de dados entre as duas redes, conhecida como ponto de divisão de dados, torna-se um fator decisivo para a experiência final do utilizador, influenciando diretamente a latência e a utilização máxima da capacidade disponível [20]. A compreensão deste ponto de divisão é fundamental para analisar o fluxo de funcionamento conceitual integrado do NSA.

Plano de Controlo no 5G NSA: A Orquestração Hierárquica pelo Ancoradouro LTE

No modelo de rede 5G Não Autónomo (NSA), o plano de controlo, que engloba todas as funções de sinalização essenciais para a operação da rede — incluindo o registo do utilizador, a autenticação, a gestão de mobilidade e o estabelecimento e libertação de sessões de dados — permanece firmemente anclado na infraestrutura de rede 4G LTE [4] [6]. Este ancoradouro é a razão fundamental pela qual o NSA não é uma arquitetura verdadeiramente autónoma e por que herda muitas das características e limitações do EPC (Evolved Packet Core) [1] [2]. A entidade central nesta esfera é a Estação Base 4G (eNB), que assume o papel de Nó Mestre (MN) dentro da conectividade dupla (EN-DC) [1] [7]. Toda a comunicação entre o dispositivo do utilizador (UE) e o núcleo de rede (EPC) flui através desta ligação LTE, o que significa que, mesmo quando o ícone "5G" está ativo na tela do telemóvel, a sinalização fundamental para manter a conexão e gerir o serviço ainda viaja pelo rádio 4G e pelo EPC [4] [7].

O fluxo de funcionamento conceitual começa assim: quando um UE 5G NSA é ligado e entra numa área de cobertura, ele primeiro procura e estabelece uma conexão com a rede LTE mais forte [6]. Esta é a sua primeira e única porta de entrada para o mundo da rede. O eNB, como nó mestre, gere a conexão RRC (Radio Resource Control) com o UE e encaminha toda a sinalização NAS (Non-Access Stratum), que contém pedidos de registo, de sessão e outras informações de nível de utilizador, para o EPC através da sua interface S1-MME [7] [15]. Dentro do EPC, a Mobility Management Entity (MME) assume a

responsabilidade de gerir a sessão e a mobilidade do UE, verificando a sua identidade e assinatura no Home Subscriber Server (HSS) [1] [2]. Toda a vida útil de uma conexão NSA está sob a jurisdição do eNB e do EPC. Quando o UE precisa de estabelecer uma sessão de dados, o pedido de sinalização viaja até à MME, que então coordena os passos necessários para a criação de um bearer (no caso da Opção 3) ou uma partilha de bearer (no caso da Opção 3x), utilizando as interfaces S1 para alcançar a Serving Gateway (SGW) e a Packet Data Network Gateway (PGW) [1] [7].

Esta estrutura hierárquica tem implicações profundas no fluxo de trabalho integrado. A gestão da mobilidade é um exemplo claro. Se um utilizador se move entre células, a decisão de realizar uma transferência (handover) é tomada pelo eNB, que age como o único ponto de autoridade para o plano de controlo [6]. As transferências envolvendo células NR requerem uma coordenação complexa e intrusiva com os procedimentos LTE existentes, o que pode introduzir latência adicional, com valores que podem variar entre 75-300 ms, comparados com os 60-100 ms de uma transferência intra-frequência LTE tradicional [6]. A gNB, embora seja capaz de medir a qualidade do sinal do lado do rádio 5G, não pode tomar decisões de controlo independentes. Ela reporta estas medições ao eNB, que as utiliza como uma das entradas para decidir se deve adicionar, remover ou ajustar a contribuição da gNB para a conexão do UE [7]. O processo de adição de uma célula NR (ou nó secundário) é iniciado pelo eNB. Ele configura o UE para medir as frequências 5G, recebe os resultados das medições e, se a condição justificar, envia um comando de Reconfiguração de Ligação RRC para o UE, instruindo-o a estabelecer uma conexão com a nova célula gNB através da interface X2-C para coordenação com o novo nó secundário [7]. Este ciclo de medição -> reporte -> decisão -> comando demonstra vividamente a natureza orquestrada e centralizada do plano de controlo no NSA.

Portanto, a visão conceitual integrada do plano de controlo no NSA é a de um sistema rigidamente hierárquico. O eNB e o EPC formam um bloco de controlo monolítico e intransponível, que exerce controle total sobre a vida útil da conexão do UE. O rádio 5G (gNB) é tratado como um recurso externo e subordinado, uma "caixa preta" de capacidade de dados cu uso é decidido e gerido exclusivamente pelo domínio 4G. A sinalização de controlo segue um caminho fixo e predeterminado: UE -> eNB -> EPC -> eNB -> UE. Esta simplicidade arquitetural foi a chave para uma rápida implementação, mas também é a fonte de limitações críticas, como a impossibilidade de suportar casos de uso que exigem decisões de controlo distribuídas, latência ultra-baixa ou a criação de redes virtuais dedicadas, que serão exploradas na arquitetura SA. O NSA entrega o controlo, mas não a liberdade.

Plano de Utilizador no 5G NSA: Agregação de Capacidade via Conectividade Dupla

Enquanto o plano de controlo no 5G NSA é preservado quase inteiramente do paradigma 4G, o plano de utilizador representa a principal inovação e o principal atrativo comercial da arquitetura NSA: o aumento massivo da largura de banda e da velocidade de transmissão de dados. Esta melhoria é alcançada através da tecnologia de conectividade dupla (EN-DC), que permite que o dispositivo do utilizador (UE) utilize simultaneamente a capacidade de rádio tanto da rede 4G (LTE) como da rede 5G (NR) para transportar o tráfego de dados [1] [6]. Conceitualmente, o objetivo é simples: aglomerar os "canos" de dados do LTE e do NR para criar um canal de transporte muito mais largo, proporcionando velocidades de download e upload muito mais elevadas do que qualquer uma das redes poderia oferecer isoladamente [2] [4]. O componente chave nesta esfera é a nova estação base 5G (gNB), que funciona como o Nó Secundário (SN) e é responsável por fornecer este canal de dados suplementar [1] [7].

A eficiência e a eficácia do plano de utilizador no NSA dependem criticamente do local onde o tráfego de dados é dividido entre as duas redes de acesso. Este ponto de divisão é um elemento arquitetural crucial que diferencia as várias variantes da opção NSA e impacta diretamente a performance, a latência e a carga sobre os diferentes nós da rede. Os materiais técnicos destacam três cenários principais, conforme definido pelo 3GPP [3] [5] [18]:

1. **Opção 3:** Neste cenário, o ponto de divisão de dados reside no eNB (Nó Mestre) [3] [5]. Todo o tráfego de dados proveniente do EPC (via SGW) chega primeiro na eNB. A eNB, então, decide quais pacotes enviar diretamente para o UE através da sua própria conexão LTE e quais outros pacotes repassar para a gNB (Nó Secundário) através da interface X2-U. A parte do tráfego que vai para a gNB é encapsulada e enviada para ela, que por sua vez entrega os dados ao UE via rádio NR [5]. A desvantagem fundamental desta abordagem é que o eNB fica num gargalo de utilização de dados. Independentemente de ter uma capacidade de rádio 5G adjacente, o volume total de dados que pode ser entregue ao UE está limitado pela capacidade de processamento e pelos enlaces de backhaul do próprio eNB. Além disso, a latência pode ser maior porque todo o tráfego de dados passa por um nó intermediário (o eNB) antes de ser distribuído.

2. **Opção 3a:** Para mitigar o gargalo do eNB, a Opção 3a posiciona o ponto de divisão de dados dentro do EPC, especificamente no nível da SGW (Serving Gateway) [3]

[5]. Nesta configuração, o eNB atua mais como um roteador passivo, recebendo todo o tráfego de dados do EPC e encaminhando-o sem processamento significativo. A SGW, agora com uma interface S1-U diretamente para a gNB, é responsável por distribuir o tráfego, enviando algumas partes para a eNB e outras para a gNB [5]. Isto alivia a carga de processamento da eNB. No entanto, esta abordagem introduz uma nova fraqueza: o EPC (ou SGW) perde a visibilidade em tempo real sobre as condições de rádio e a capacidade de processamento das estações base. A alocação de carga torna-se estática e menos adaptativa, pois não pode responder dinamicamente a flutuações momentâneas na qualidade do sinal NR ou na congestão da célula gNB, o que pode levar a uma experiência de utilizador inferior quando o sinal 5G é fraco [3].

3. **Opção 3x (Recomendada):** A Opção 3x representa a implementação mais eficiente e sofisticada do NSA. Nela, o ponto de divisão de dados é movido para a gNB (Nó Secundário) [3][17][18]. O tráfego de dados do EPC (proveniente da PGW) pode ser roteado diretamente para a gNB através de uma interface S1-U [18]. Uma vez que a gNB recebe o tráfego, ela toma a decisão inteligente de dividir o fluxo de dados: uma parte é enviada diretamente ao UE via rádio NR, enquanto outra parte, se necessário, pode ser encaminhada para a eNB através da interface X2-U para ser entregue ao UE via rádio LTE [19]. Esta arquitetura maximiza a utilização da capacidade de rádio 5G, reduz a latência (pois o tráfego de dados não é obrigatoriamente roteado através da eNB) e evita o gargalo de processamento no nó mestre [17][20]. A decisão de divisão de dados pode ser dinâmica, com a gNB ajustando a proporção de tráfego 4G vs. 5G com base em parâmetros em tempo real como a carga da rede e a qualidade do canal [19]. Este mecanismo é frequentemente gerido através de um mecanismo de feedback chamado Status de Entrega de Dados Descarregados (DDDS), onde a gNB informa a eNB sobre o número de sequência PDCP mais alto entregue, permitindo que a eNB regule a taxa de dados enviada para a gNB [19].

Em resumo, a visão conceitual integrada do plano de utilizador no NSA é a de uma operação de agregação de largura de banda coordenada. Embora a sinalização de controlo siga um caminho rígido e monopólico (LTE), o tráfego de dados pode seguir um caminho flexível e distribuído. A escolha da Opção 3x, em particular, demonstra uma tentativa de otimizar o melhor dos dois mundos: usar a robustez e a cobertura do LTE para a sinalização crítica, enquanto liberando o potencial máximo do rádio 5G para os dados, com a gNB a funcionar como um ponto de divisão de dados inteligente e eficiente. No entanto, é importante reiterar que esta flexibilidade está confinada ao plano de

utilizador e que a dependência fundamental do domínio LTE para o controlo permanece uma limitação arquitetónica fundamental.

A Revolução Nativamente da Nuvem: Os Pilares Arquiteturais do 5G Autónomo

Em contraste direto com a abordagem de transição pragmática do 5G Não Autónomo (NSA), o 5G Standalone (SA) representa uma revolução arquitetónica projetada desde o zero para ser uma plataforma de rede verdadeiramente independente, programável e escalável [9] [20]. O seu design não se baseia em superpor novas funcionalidades a uma infraestrutura legada, mas sim em reconstruir o núcleo da rede do chão para cima, adoptando princípios modernos de computação em nuvem e arquitetura de software. Esta mudança radical é sustentada por dois pilares fundamentais que definem a sua filosofia: a Arquitetura Baseada em Serviços (SBA - Service-Based Architecture) e a Separação Explícita de Plano de Controlo e Plano de Utilizador (CUPS - Control and User Plane Separation) [3] [8] [16]. Juntos, estes pilares transformam o núcleo de rede de um conjunto de caixas-preta monolíticas e interligadas em uma coleção de microserviços modulares, elásticos e que se comunicam através de APIs padronizadas, criando uma plataforma ideal para os casos de uso avançados que a tecnologia 5G prometeu.

A Arquitetura Baseada em Serviços (SBA) é a alteração mais profunda na forma como as funções de controlo da rede interagem. Substitui as interfaces rígidas e ponto a ponto do EPC por um modelo onde as funções de rede (NFs - Network Functions) são modularizadas como serviços que se comunicam uns com os outros através de interfaces baseadas em API (SBIs - Service-Based Interfaces) [3] [9]. Em vez de um nó ter uma ligação física e dedicada a outro, as NFs publicam os serviços que oferecem (ex: "gestão de mobilidade", "criação de sessão") no que é conceptualmente uma "loja de aplicações" digital, conhecida como o Repositório de Funções de Rede (NRF - Network Repository Function) [8]. Outras NFs podem consultar o NRF para encontrar as instâncias disponíveis de um determinado serviço, eliminando a necessidade de configurações estáticas complexas e tornando a rede infinitamente mais flexível e adaptável [15]. Esta comunicação via API, tipicamente usando HTTP/2 e JSON, permite que cada NF seja desenvolvida, implantada, atualizada e dimensionada de forma independente, seguindo os princípios da virtualização e dos contêineres (como Docker e Kubernetes) [8] [16].

O segundo pilar, a Separação Explícita de Plano de Controlo e Plano de Utilizador (CUPS), extende uma melhoria já vista no EPC para toda a arquitetura [1] [3]. No núcleo 5G, esta separação é absoluta. O plano de controlo, que lida com todos os aspetos de sinalização, gestão de sessões, políticas e mobilidade, é gerido por um conjunto de NFs de controlo. O plano de utilizador, que é puramente responsável pelo encaminhamento eficiente de pacotes de dados brutos, é gerido por uma única NF, a User Plane Function (UPF) [3] [12]. Esta desconexão permite uma granularidade de dimensionamento e otimização sem precedentes. Por exemplo, se o tráfego de dados aumentar numa determinada região, os operadores podem simplesmente adicionar mais instâncias de UPFs nesse local, sem precisarem de dimensionar todo o sistema de controlo. Inversamente, se o número de dispositivos a registar aumentar, eles podem dimensionar horizontalmente as instâncias de AMF (Access and Mobility Management Function) [16]. Esta flexibilidade é crucial para otimizar a latência e a eficiência da rede, permitindo que as UPFs sejam distribuídas geograficamente para a borda da rede (Edge Computing), um tópico que será explorado posteriormente. Juntamente, o SBA e o CUPS criam uma arquitetura nativa da nuvem, resiliente, escalável e programável, que é a verdadeira essência do 5G SA e a base para as suas capacidades avançadas [9].

Plano de Controlo no 5G SA: A Colaboração Descentralizada na Arquitetura Baseada em Serviços

No 5G Standalone (SA), o plano de controlo sofre uma transformação conceitual profunda em comparação com o NSA. Em vez de um modelo hierárquico e centralizado liderado pelo eNB, o plano de controlo no 5G SA opera como um ecossistema colaborativo e descentralizado de microserviços interligados pela Arquitetura Baseada em Serviços (SBA) [8] [9]. Nesta arquitetura, as funções de controlo, chamadas de Funções de Rede (NFs), não são mais caixas-preta monolíticas, mas sim serviços independentes que se comunicam através de APIs padronizadas sobre o Service-Based Interface (SBI) [3] [4]. Esta mudança de paradigma permite uma flexibilidade, escalabilidade e resiliência sem precedentes. O fluxo de funcionamento conceitual integrado do plano de controlo não é mais um caminho linear, mas sim um processo de descoberta e orquestração dinâmica, onde cada NF executa a sua tarefa especializada e colabora com outras para alcançar um objetivo comum: o registo do utilizador e a preparação para a troca de dados.

O processo começa quando um UE 5G SA se liga à nova estação base 5G (gNB) e inicia o seu procedimento de acesso inicial [16]. A gNB atua como a ponte entre o rádio e o núcleo,

encaminhando a sinalização NAS-MM (Mobility Management) do UE para a NF de controlo correspondente no núcleo 5G. Esta função é a Access and Mobility Management Function (AMF) [8] [16]. A AMF funciona como a porta de entrada e o âncora de controlo para o UE na rede [16]. A sua primeira tarefa é receber o pedido de registo, verificar a identidade do UE e iniciar o processo de autenticação, que utiliza o método 5G-AKA (Authentication and Key Agreement) [4]. Para isso, a AMF pode precisar de consultar outras NFs. Utilizando o NRF (Network Repository Function) como um diretório de serviços, ele descobre e contacta a Authentication Server Function (AUSF) para executar o processo de autenticação e a Unified Data Management (UDM) para recuperar as informações de assinante e credenciais necessárias [4] [15]. Uma vez que o registo e a autenticação são bem-sucedidos, o AMF sabe que o UE está registado na rede.

Se o UE solicitar a criação de uma sessão de dados (conhecida como PDU session), o fluxo de trabalho torna-se ainda mais dinâmico e colaborativo. A AMF não gerencia diretamente a sessão de dados; ela transfere essa responsabilidade para a Session Management Function (SMF) [11] [14]. Novamente, utilizando o NRF, o AMF consulta o serviço de descoberta de NFs para encontrar uma ou mais SMFs adequadas para lidar com o pedido [15]. A seleção da SMF pode ser baseada em vários critérios, como a localização do UE, a DNN (Data Network Name) solicitada (por exemplo, internet pública ou uma rede privada específica) ou o S-NSSAI (Single Network Slice Selection Assistance Information) se um Fatiamento de Rede estiver envolvido [9] [11]. Uma vez que uma SMF é selecionada, a AMF encaminha o pedido de gestão de sessão para ela, juntamente com a informação de contexto da ligação N2 obtida da gNB [14] [16].

A SMF agora assume o controlo total da gestão da sessão. A sua primeira tarefa é garantir a conformidade da assinatura consultando a UDM através do NRF para obter os dados da subscrição do utilizador [15]. Em seguida, a SMF precisa de selecionar uma UPF (User Plane Function) para ser o ponto de ancoragem para o tráfego de dados daquela sessão específica [11] [14]. Mais uma vez, a seleção da UPF pode ser influenciada por fatores como a localização geográfica pretendida para minimizar a latência ou a carga atual da UPF. Após selecionar uma UPF, a SMF estabelece uma sessão de controlo com ela através da interface N4, utilizando o protocolo PFCP (Packet Forwarding Control Protocol) [14] [15]. Finalmente, para garantir que o serviço prestado atenda aos requisitos de qualidade, a SMF consulta a Policy Control Function (PCF) através do NRF para obter as políticas de QoS e de cobrança relevantes para a sessão [11] [14]. Com todas as peças em vigor — contexto de sessão, UPF selecionada, políticas de QoS aplicáveis —, a SMF está pronta para programar o plano de utilizador.

Este fluxo demonstra a natureza integrada e orientada a serviços do SA. Não há um "mestre" que dita ordens; em vez disso, existe um processo de descoberta e colaboração. O AMF encontra a SMF certa, a SMF encontra a UPF e as políticas certas, e todos eles trabalham em conjunto para criar um objeto de estado rico chamado PDU session. Este objeto não é apenas um túnel de dados, mas encapsula o contexto completo da sessão, incluindo a IP do UE, as políticas de QoS, o ponto de ancoragem no plano de utilizador e as regras de política aplicáveis [11]. Esta abordagem modular e colaborativa é a base para as capacidades avançadas do 5G, como o fatiamento de rede e a computação na borda, pois permite que o plano de controlo tome decisões inteligentes e programáveis sobre como configurar o plano de utilizador para atender a casos de uso específicos.

Plano de Utilizador no 5G SA: Distribuição Inteligente e Programável do Encaminhamento de Dados

O plano de utilizador no 5G Standalone (SA) é o reflexo direto da filosofia de separação explícita de plano de controlo e plano de utilizador (CUPS) que define a sua arquitetura [3] [16]. Enquanto no NSA o plano de utilizador é uma operação agregada e centralizada sob o controlo do eNB, no SA ele torna-se um serviço distribuído, programável e altamente otimizado. O componente central e único responsável pelo encaminhamento de pacotes de dados no plano de utilizador é a User Plane Function (UPF) [3] [12]. A UPF é, em essência, um roteador virtualizado e inteligente que se situa na fronteira entre a rede de acesso por rádio (RAN) e as redes de dados externas (DNs), como a Internet [11] [12]. A sua função é simples mas crítica: receber pacotes de dados do gNB, aplicar regras de encaminhamento e QoS, e encaminhá-los para o destino correto, que pode ser um servidor na Internet ou outra rede [11] [12].

A grande inovação do plano de utilizador no SA não reside apenas na existência da UPF, mas na sua natureza distribuída e programável. Graças à separação do controlo, os operadores podem implantar múltiplas instâncias da UPF em diferentes locais geográficos dentro da sua infraestrutura de rede [3] [12]. Uma UPF pode estar localizada num data center central, enquanto outra pode estar instalada fisicamente perto de uma estação base na borda da rede, num local de processamento multi-acesso (MEC), ou até mesmo num centro de dados do cliente [3] [12]. Esta capacidade de colocar o plano de utilizador "onde o dado está" ou "onde o dado precisa de ir" é o que permite a redução drástica da latência, um requisito crítico para muitos casos de uso de 5G [12].

O fluxo de funcionamento conceitual integrado do plano de utilizador no SA é diretamente orquestrado pelo plano de controlo. Começa quando a Session Management Function (SMF) seleciona uma UPF para uma nova PDU session, como descrito anteriormente [11] [14]. A SMF então utiliza a interface N4, com o protocolo PFCP, para programar a UPF, fornecendo-lhe as regras exatas sobre como tratar o tráfego daquela sessão [14] [15]. Estas regras são definidas em estruturas de dados como Regras de Detecção de Pacote (PDRs), Regras de Acção de Encaminhamento (FARs), Regras de Aplicação de QoS (QERs) e Regras de Relatório de Utilização (URRs) [11]. Por exemplo, uma PDR pode dizer à UPF: "Encaminhe todos os pacotes que correspondam a este padrão de fluxo de dados para este FAR". O FAR, por sua vez, pode instruir a UPF a encapsular os pacotes num túnel GTP-U e enviá-los para um endereço IP específico (a gNB ou outro UPF) [11].

Quando tudo está pronto, a SMF informa o AMF, que por sua vez instrui a gNB a configurar os recursos de rádio para o novo fluxo de dados [16]. A gNB, por sua vez, estabelece túneis GTP-U ponto-a-ponto com a UPF através da interface N3 [11] [16]. Para o tráfego de subida (do UE para a Internet), a gNB encapsula os pacotes IP do UE num túnel GTP-U com o Endereço de Terminal de Encaminhamento de Dados (TEID) e o endereço IP da UPF como destino. Para o tráfego de descida (da Internet para o UE), a gNB usa o TEID e o endereço IP da própria gNB como origem, encaminhando os pacotes recebidos da UPF [11]. A UPF, por sua vez, retira o cabeçalho GTP-U e encaminha os pacotes de dados brutos para a próxima paragem, geralmente através da interface N6 para a rede de dados externa [12] [16].

Esta arquitetura permite cenários de ponta avançados. Por exemplo, se uma PDU session for destinada a uma aplicação local, como um servidor de jogos num centro de dados MEC, a SMF pode selecionar deliberadamente uma UPF localizada nesse centro de dados. Assim, o tráfego de dados nunca sai da rede regional, resultando numa latência extremamente baixa [3] [12]. Este mecanismo, conhecido como ruptura local, é impossível de implementar eficientemente no NSA, onde todo o tráfego de dados é forçado a viajar até um centro de dados central do EPC, muitas vezes centenas de quilómetros de distância [12]. Portanto, a visão conceitual integrada do plano de utilizador no SA é a de um sistema de encaminhamento de dados altamente flexível e programável, onde a lógica de controlo (SMF) e a lógica de execução (UPF) estão explicitamente separadas e podem ser otimizadas independentemente, permitindo que a infraestrutura de rede seja adaptada dinamicamente às necessidades de qualquer aplicação, desde streaming de vídeo de alta definição até controlo remoto de equipamentos industriais com requisitos de latência rigorosos.

Referência

1. Understanding 5G NSA Core Architecture with EN-DC and ... https://www.linkedin.com/posts/abhijeetkumar2050_5g-telecom-5garchitecture-activity-7371809445535727616-vM71
2. Theory of 5G NSA Core Architecture (EN-DC Option 3x + ... https://www.telecomhall.net/t/theory-of-5g-nsa-core-architecture-en-dc-option-3x-cups/35151
3. 5G Networking Modes https://www.nextgcomm.com/5g-networking-modes/
4. 5G SA vs NSA Explained: Architecture, Anchor, and Field ... https://hicelltek.com/en/blog/5g-sa-vs-nsa-explained/
5. 5G Deployment Options https://devopedia.org/5g-deployment-options
6. 5G network deployment possibilities https://www.mediatek.com/tek-talk-blogs/5g-network-deployment-possibilities
7. Interworking with LTE - NSA / ENDC in Detail https://www.sharetechnote.com/html/5G/5G_LTE_Interworking.html
8. 5G Core Network (5GC) Explained | SBA, AMF, SMF, UPF, ... https://www.3glteinfo.com/5g/architecture/core-network/
9. 5G NR SA (Standalone) Architecture Overview https://www.linkedin.com/pulse/5g-nr-sa-standalone-architecture-overview-ravi-shekhar-saa0c
10. 5G PDU Session Establishment Process Explained https://www.linkedin.com/posts/nitingupta639_your-phone-is-registered-on-5g-what-happens-activity-7508870969453760512-nxoV
11. 5G Data Session: An End-to-End Call Flow Deep Dive https://medium.com/@anand.hv123/5g-data-session-an-end-to-end-call-flow-deep-dive-ac896df596e6
12. Understanding User Plane Function (UPF) in 5G https://flolive.net/blog/glossary/understanding-user-plane-function-upf-in-5g-a-practical-guide/
13. Ultra Cloud Core 5G User Plane Function, Release 2022.01 https://www.cisco.com/c/en/us/td/docs/wireless/ucc/upf/2022-01/config-and-admin/b_ucc-5g-upf-config-and-admin-guide_2022-01/m_upf-overview.html
14. 5G SMF: Use Cases, Key Functions & Deployment Best ... https://flolive.net/blog/glossary/5g-smf-use-cases-key-functions-and-deployment-best-practices/

15. What is the 5G Session Management Function (SMF)? https://techcommunity.microsoft.com/blog/telecommunications-industry-blog/what-is-the-5g-session-management-function-smf/3693852
16. AMF vs SMF vs UPF: What Each 5G Core Network ... https://www.5g6gacademy.com/learn/amf-smf-upf-roles
17. 5G NR NSA Architecture Overview https://www.techedgewireless.com/post/5g-nr-nsa-architecture-overview
18. 5G NSA Option 3.x Deployment Interface BW Calculation https://www.techplayon.com/5g-nsa-option-3-x-deployment-interface-bw-calculation/
19. Data Split Determination in 5G NSA Option 3X https://www.telecomhall.net/t/data-split-determination-in-5g-nsa-option-3x/32825
20. 5G NSA and SA Network Modes https://www.hocell.com/newsinfo/534439.html